強化學習演算法綜合分析報告：從 DQN 到 Dueling 架構

技術原理、數學推導與實驗結果之完整彙編

1. 實驗結果總結

本報告旨在對深度強化學習（Deep RL）中三種核心演算法進行系統性評估。根據實驗數據，改進型架構在成功率與訓練穩定性上皆展現出壓倒性的優勢。

演算法類型	測試成功率	Loss 收斂速度	策略穩定性
DQN	90.5%	慢 (持續波動)	中等
Double DQN	**100.0%**	**快 (7.5k步收斂)**	高
Dueling DQN	**100.0%**	**極快 (極度平滑)**	極高

2. DQN 效能分析與局限性

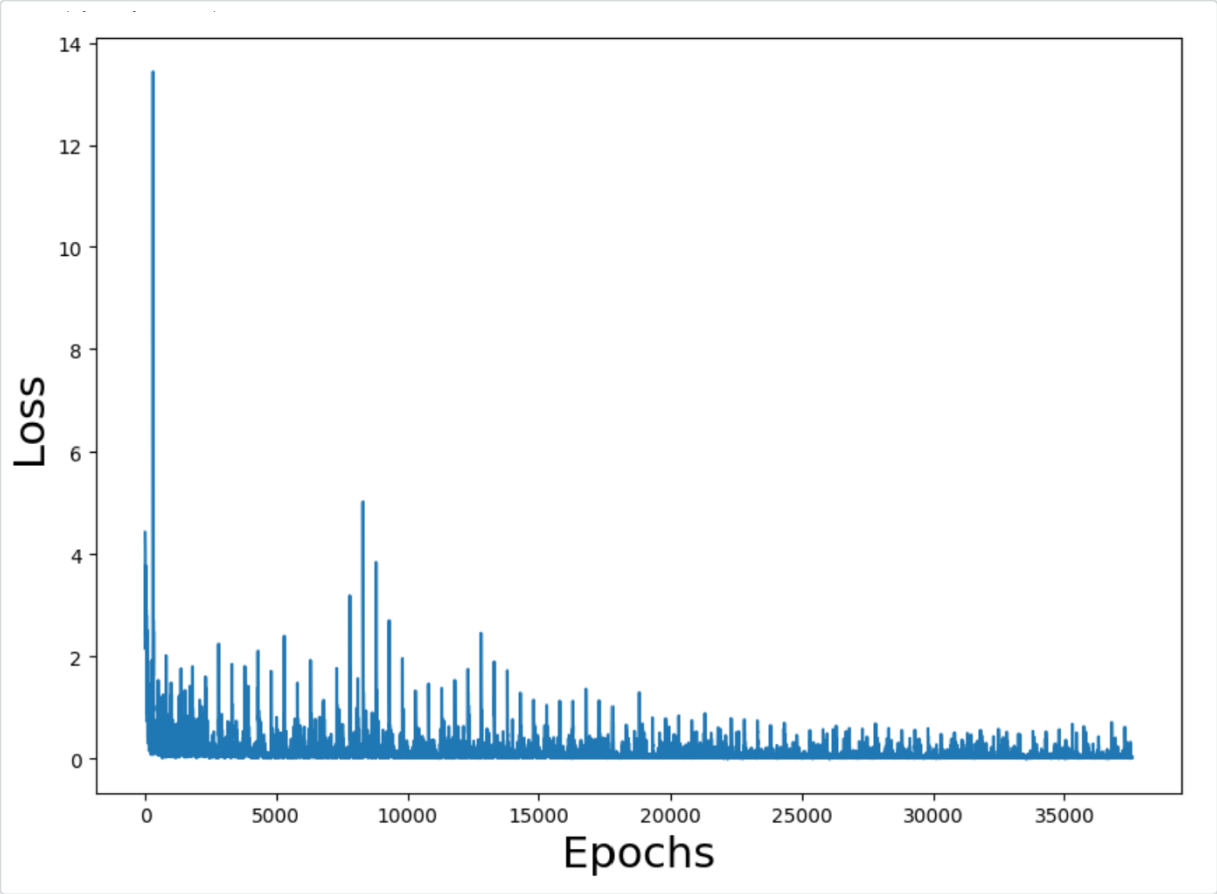

圖 1：DQN 訓練過程中的 Loss 曲線 (波動劇烈)

DQN 成功結合了卷積神經網路與 Q-Learning，但存在嚴重的數值偏誤問題。由圖 1 可見其 Loss 曲線在訓練後期仍有明顯雜訊，這主要源於目標值的計算方式。

3. Double DQN：修正過度估計 (Overestimation)

3.1 技術改良重點

在原始 DQN 中，同一個目標網路 θ^- 被用來同時進行動作選擇與價值評估。由於 max 操作會傾向於選擇被雜訊高估的動作，導致 Q 值預測遠高於實際價值。

DQN 目標值計算：

$$Y_t^{DQN} = R_{t+1} + \gamma \max_a Q(S_{t+1}, a; \theta^-)$$

Double DQN 引入了「解耦」機制，利用目前訓練網路 θ 來選取最佳動作，再利用目標網路進行評估：

Double DQN 改良公式：

$$Y_t^{DDQN} = R_{t+1} + \gamma Q(S_{t+1}, \operatorname{argmax}_a Q(S_{t+1}, a; \theta); \theta^-)$$

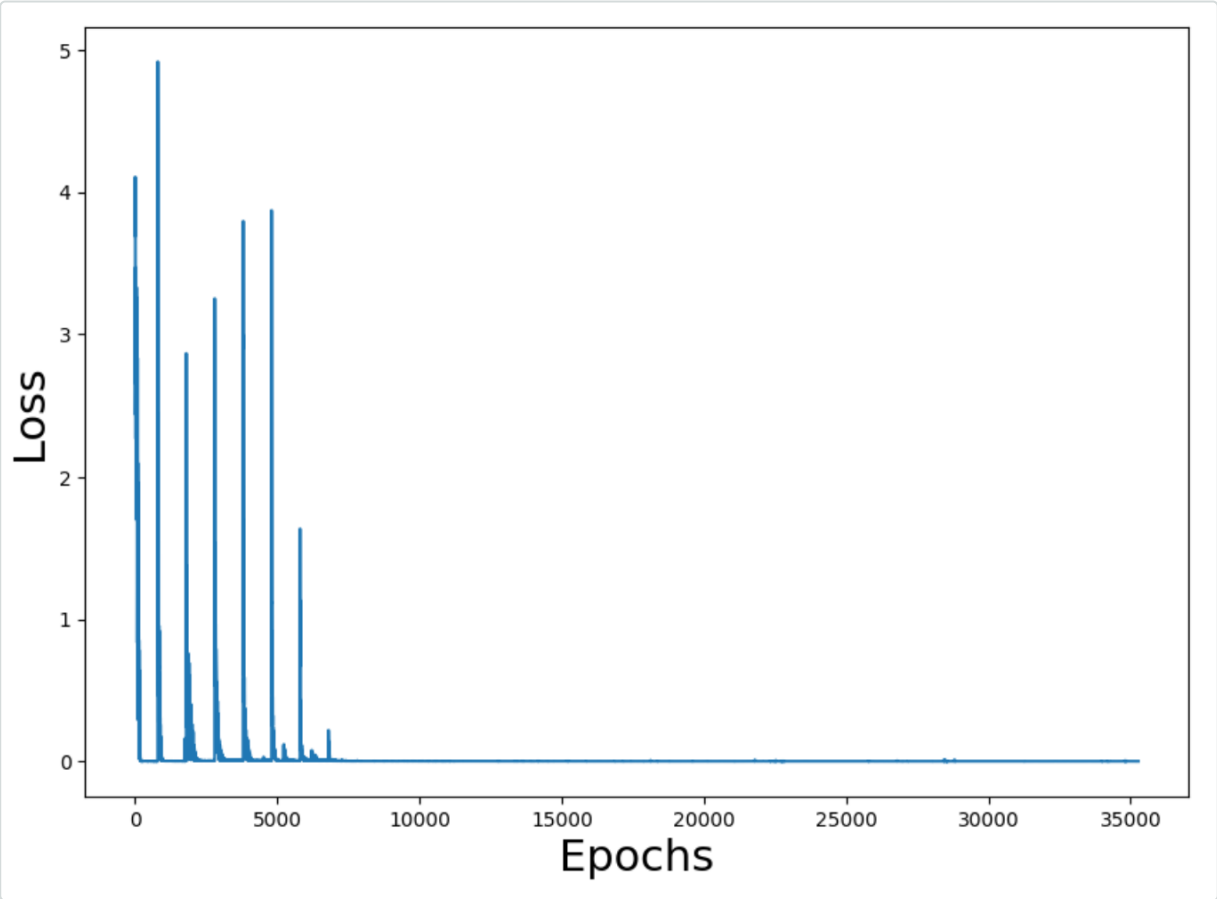

圖 2：Double DQN 之 Loss 曲線 (收斂後極度穩定)

實驗成效：如圖 2 所示，修正偏誤後 Loss 曲線在初期震盪後迅速趨近於 0，最終測試成功率達到 **100%**。

4. Dueling DQN：優化狀態價值表達

4.1 技術改良重點

Dueling DQN 改變了網路的拓樸結構。它不直接預測每個動作的 Q 值，而是將 Q 值分解為狀態價值函數 ***V(s)*** 與優勢函數 ***A(s, a)***。

Dueling DQN 架構公式：

$$Q(s, a; \theta, \alpha, \beta) = V(s; \theta, \beta) + (A(s, a; \theta, \alpha) - 1/|A| \Sigma_{a'} A(s, a'; \theta, \alpha))$$

改良成效：該設計能更精確地識別哪些狀態是關鍵的，即使在某些動作不常被執行的情況下也能有效更新狀態價值。

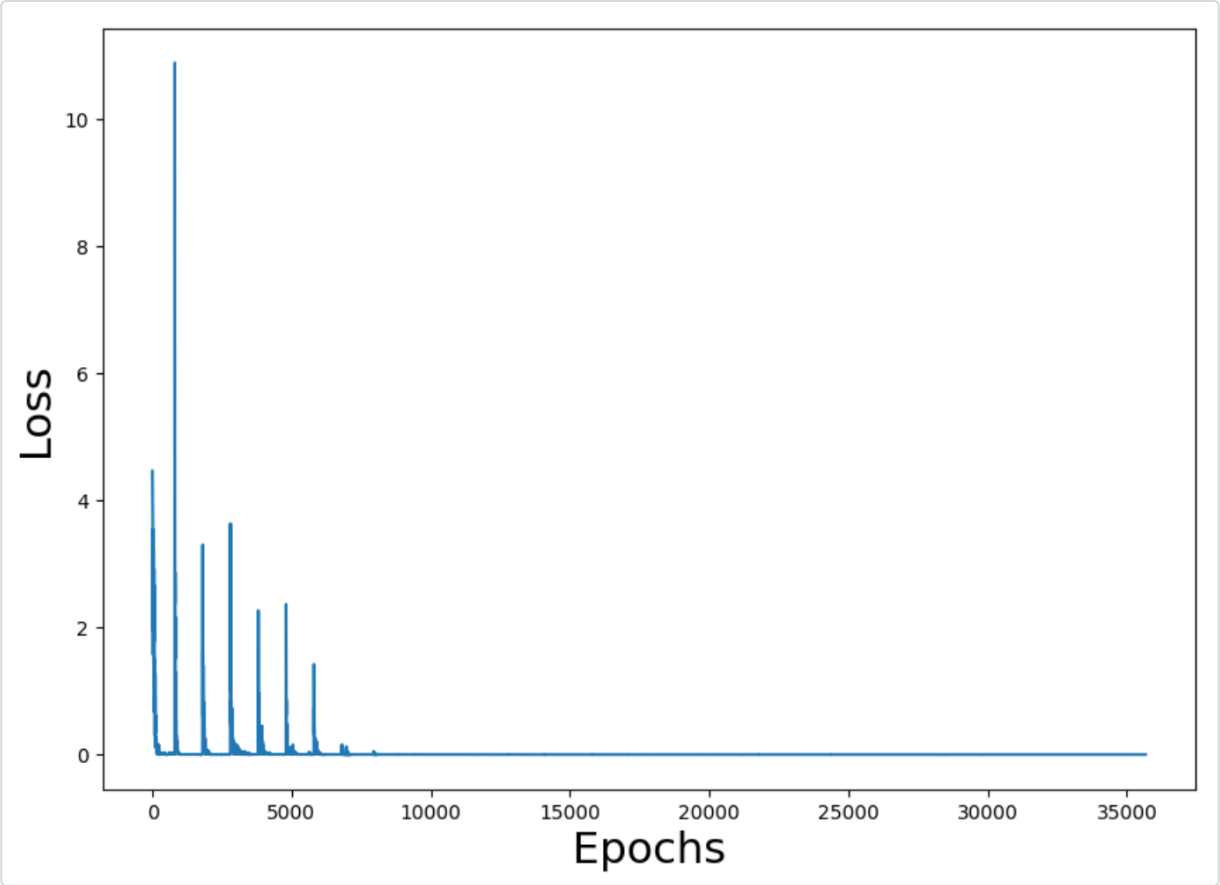

圖 3：Dueling DQN 之 Loss 曲線 (最為平滑之收斂)

由圖 3 可見，其收斂穩定性更勝 Double DQN，成功率同樣穩定維持在 **100%**。

5. 參考論文來源 (References)

[1] DQN: Mnih, V., Kavukcuoglu, K., Silver, D., et al. (2015). "Human-level control through deep reinforcement learning." *Nature*, 518(7540), 529-533.

[2] Double DQN: van Hasselt, H., Guez, A., & Silver, D. (2016). "Deep Reinforcement Learning with Double Q-learning." *Proceedings of the AAAI Conference on Artificial Intelligence*, 30(1).

[3] Dueling DQN: Wang, Z., Schaul, T., Hessel, M., et al. (2016). "Dueling Network Architectures for Deep Reinforcement Learning." *International Conference on Machine Learning (ICML)*.