強化學習技術分析報告：Rainbow DQN 與經典變體之架構剖析與性能對比

撰寫時間：*2026* 年 *5* 月 | 專題：深度 *Q* 網路 *(DQN)* 變體研究、損失函數收斂機制與實驗診斷

一、 引言

在深度強化學習（Deep Reinforcement Learning, DRL）的演進歷程中，深度 Q 網路（DQN）的提出無疑是一個重要的里程碑。然而，經典 DQN 面臨著諸多不穩定性與理論缺陷，例如高估偏差（Overestimation Bias）、不穩定的目標更新以及缺乏重點經驗採樣等。為了克服這些局限性，學術界相繼提出了 Double DQN、Dueling DQN、優先經驗回放（PER）以及多步學習（Multi-step Learning）等改良機制，並最終由 DeepMind 整合為集大成者 —— **Rainbow DQN**。

本報告將基於近期在 4x4 網格世界（Gridworld）環境下的實驗觀測，深入解析各演算法在「損失函數（Loss Curve）」與「實際勝率（Win Rate）」上的反差表現，並探討這些演算法本質上的數學機制與探索策略。同時，報告將對無人機（UAV）自主導航與動態避障等複雜控制任務給出工程實踐建議。

二、 核心演算法架構剖析

1. Double DQN (DDQN) — 解耦動作選擇與評估

傳統 DQN 在計算目標 Q 值時，使用相同的網路參數同時進行動作選擇和價值評估，這會導致顯著的高估偏差。Double DQN 的核心思想在於將兩者解耦：

- **動作選擇（Selection）：** 使用當前預測網路（Main Network, θ）選出在下一個狀態 S_{t+1} 下的最優動作 a^*。
- **動作評估（Evaluation）：** 使用目標網路（Target Network, θ^-）計算該動作 a^* 的 Q 值。

其目標值 $Y_t^{DoubleQ}$ 計算公式如下：

$$Y_t^{DoubleQ} = R_{t+1} + \gamma\, Q(S_{t+1}, \operatorname{argmax}_a Q(S_{t+1}, a; \theta_t); \theta_t^-)$$

代碼中藉由 `model(state2_batch)` 獲取動作索引，並由 `model2(state2_batch)` 計算 Q 值的邏輯，完美體現了這一數學公式。這種解耦能夠顯著降低 Q 值的過度估計，使模型訓練更為穩定。

2. Dueling DQN — 狀態價值與優勢函數的分流

Dueling DQN 藉由修改神經網路的最後幾層架構，將 Q 值函數拆解為「狀態價值函數 $V(s)$」與「動作優勢函數 $A(s, a)$」兩部分：

$$Q(s, a; \theta, \alpha, \beta) = V(s; \theta, \beta) + \left(A(s, a; \theta, \alpha) - 1/|A| \sum_{a'} A(s, a'; \theta, \alpha) \right)$$

其中，θ 為共享的特徵提取層參數，β 與 α 分別為狀態價值分支與動作優勢分支的專有參數。透過減去優勢函數的平均值，確保了模型輸出的唯一性與識別度。這使得智能體在許多「動作選擇對狀態轉移影響不大」的場景下，能更高效地學習狀態本身的絕對價值。

3. Multi-step Learning (N-step) — 折衷偏差與方差

傳統的單步 Q 學習只利用下一時刻的即時獎勵 R_{t+1} 與單步引導（Bootstrapping）來更新模型。而 N-step 學習則向前延伸了 N 步，其 N 步折現回報公式為：

$$G_{t:t+n} = \Sigma_{i=1}^{n} \gamma^{i-1} R_{t+i} + \gamma^{n} max_{a} Q(S_{t+n}, a)$$

在我們所實作的 Rainbow DQN 中，n_step **設定為 3 步**。這種設定延遲了時間差分（TD）誤差的引導，能將遠端獎勵信號更快地向前期狀態回傳，加速收斂速度。但代價是引入了更多環境軌跡的方差。

三、 實驗診斷：Loss 曲線與實際表現的「悖論」

在實際實驗中，使用者往往會觀察到一個有趣的現象：**DQN Soft Update、Double DQN 與 Dueling DQN 的 Loss 曲線極為平滑且數值接近於零，測試勝率高達 91.0% 至 100.0%；而最為先進的 Rainbow DQN 卻呈現出劇烈震盪且絕對數值極高的 Loss 曲線。**

這一現象在機器學習中常被誤解為訓練失敗，但實質上它是多種先進演算法機制相互作用下的「健康」體現。下表整理了四種演算法在此實驗設定下的核心數據與機制特徵：

演算法	網格勝率	Loss 曲線形態	經驗回放採樣機制	探索與擾動機制	步數延遲 (N-step)
DQN Soft Update	91.0%	極平滑，趨近於 0	隨機均勻抽樣	ε-greedy (靜態網路)	單步 (1-step)
Double DQN	100.0%	極平滑，快速收斂	隨機均勻抽樣	ε-greedy (靜態網路)	單步 (1-step)
Dueling DQN	100.0%	極平滑，快速收斂	隨機均勻抽樣	ε-greedy (靜態網路)	單步 (1-step)
Rainbow DQN	高勝率 (動態多變)	劇烈鋸齒狀震盪，數值高	優先經驗回放 (PER)	Noisy Networks (權重抖動)	多步 (3-step 延遲)

關鍵機制解析：為什麼 Rainbow DQN 的 Loss 看起來「比較差」？

1. **優先經驗回放 (PER) 的篩選效應：** 傳統 DQN 在訓練後期，經驗回放區充斥著大量已經學會的「簡單經驗」（TD-Error ≈ 0）。隨機均勻抽樣會不斷抽取這些簡單樣本，導致計算出來的平均 Loss 極低。而 PER 則刻意提高 TD-Error 大（預測最不準）之樣本的抽樣權重。這意味著神經網路每一輪都在挑戰當下「最難的題目」，計算出來的 Loss 數學上必然會大幅提高。
2. **Noisy Networks 的持續探索：** 傳統演算法在推論與訓練更新時網路權重是固定的（透過 ε-greedy 在外部選擇隨機動作）。而 Noisy DQN 則是直接在神經網路的線性層權重中注入可學習的隨機雜訊。這種機制迫使網路在每一次前向傳播時，參數都在進行「微小抖動」，從而確保了持續的內部探索。這使得網路無法像 DDQN 那樣靜止擬合，進而造成 Loss 的波動與鋸齒狀外觀。
3. **N-step 帶來的隨機方差：** 3-step 延遲累積了連續三步的隨機回報。在隨機地形（`mode='random'`）中，這顯著增加了目標值 Y_t 的變異數（Variance），並直接轉化為 MSE 損失的突波。

四、「殺雞焉用牛刀」：4x4 網格世界的特殊性

在我們測試的 4x4 網格世界中，整個狀態空間僅有 16 個格子（展開為 64 維特徵），且環境是完全可觀測的。這種「玩具級」任務具備極低的複雜度：

- **過擬合與過度探索：** 由於環境過於單純，Double DQN 與 Dueling DQN 的擬合能力已處於飽和狀態。它們不需要像 Rainbow DQN 那樣使用 Noisy Networks 進行深度的參數空間探索，僅憑簡單的隨機策略即可在極短時間內摸清全局最優解，並將 Loss 沉澱。
- **複雜機制的反噬：** Rainbow DQN 猶如一台「裝甲坦克」。在 4x4 的微型網格中，PER 和 Noisy Nets 帶來的額外擾動反而成了噪聲干擾，使得 Loss 出現不必要的波動。這正說明了在強化學習中：**演算法並非越複雜越好，應根據任務環境的複雜度（Task Complexity）進行合理選型。**

五、無人機（UAV）自主導航與避障的工程啟示

將上述分析映射到高維度、具備隨機干擾的真實世界控制任務（如無人機自主三維導航、動態避障）中，Rainbow DQN 的優勢將完全展現，而簡單變體則會面臨瓶頸：

無人機控制工程實踐建議

- **擁抱 Rainbow 的不穩定 Loss：** 在 3D 空間飛行時，無人機 99% 的時間都在空曠區域飛行（TD-Error ≈ 0），只有在極少數「即將碰撞障礙物」或「成功穿過狹窄通道」的臨界狀態下，才會產生關鍵的獎勵變化。PER 能強制模型專注於這 1% 的「生死關頭」，雖然會讓訓練日誌中的 Loss 曲線顯得極其混亂與震盪，但這正是避障策略成功建立的保證。
- **Noisy Networks 優於 ε-greedy：** 在物理世界中，若採用 ε-greedy，無人機在探索時會做出無意義的高頻隨機抖動，這在工程上極易導致硬體受損或姿態失穩。Noisy Networks 能在參數空間提供平滑且具備時間關聯性的「策略性探索」，讓無人機學會連貫的繞行與爬升動作。
- **N-step 緩解獎勵稀疏（Sparse Reward）：** 導航任務通常只有在到達終點時才有大獎勵，單步 DQN 的獎勵回傳極慢。採用 3-step 甚至 5-step 的延遲，可以將終點的獎勵以幾何級數的速度回傳給先前的航點決策，大幅縮短無人機摸索最優路徑的時間。

六、 結論

經過深度對比，我們可以得出以下工程結論：

1. **不要盲目追求「平滑、趨近於零的 Loss 曲線」：** 在 DRL 中，平滑的 Loss 通常源自於隨機抽樣對簡單樣本的過度擬合（如 Soft Update 或 DDQN 處理小網格）；而高且震盪的 Loss 往往是 PER 和持續探索機制的必然產物。
2. **任務規模決定演算法選型：** 對於離散、完全觀測且狀態空間小於 1000 的環境，Double DQN 或 Dueling DQN 搭配均勻經驗回放是更為經濟高效的選擇；而面對高維度、連續觀測（如相機畫面、雷達點雲）以及隨機動態干擾的任務（如無人機導航），Rainbow DQN 則是突破性能上限的必備架構。

報告完畢。本技術報告旨在為深度強化學習算法的超參數調優與架構選型提供理論支持與工程指導。